

# Основы машинного обучения

## Контрольная работа

### Вариант 1

**Задача 1 (3 балла).** В этой задаче мы будем обсуждать модель линейной регрессии  $a(x) = \langle w, x \rangle$ . Ответьте на вопросы:

1. Часто линейные модели обучают с помощью градиентного спуска. Формула шага в нём выглядит так:

$$w^{(t)} = w^{(t-1)} - \eta_t \nabla_w Q(w^{(t-1)}).$$

Ниже предложено три варианта формул для длины шага. Объясните для каждого из них, какие проблемы могут возникнуть в градиентном спуске при его использовании.

- $\eta_t = t$ ;
- $\eta_t = \sin(t)$ ;
- $\eta_t = \frac{1}{100^t}$ .

2. Мы обучаем линейную регрессию на среднеквадратичную ошибку:

$$\frac{1}{\ell} \sum_{i=1}^{\ell} (\langle w, x_i \rangle - y_i)^2 \rightarrow \min_w$$

Такой подход имеет какие-то смещение и разброс. Напишите, как по сравнению с этим подходом изменятся смещение и разброс у следующих модификаций, и поясните, почему вы так считаете:

- $\frac{1}{\ell} \sum_{i=1}^{\ell} (\langle w, x_i \rangle - y_i)^2 + \|w\|_2^2 \rightarrow \min_w$ ;
- $\frac{1}{\ell} \sum_{i=1}^{\ell} (\langle w, x_i \rangle - 1)^2 \rightarrow \min_w$ ;

3. Ниже записан функционал для некоторой модели:

$$\frac{1}{\ell} \sum_{i=1}^{\ell} \left( w_0 + w_1 x_{i1}^{\alpha} + w_2 x_{i2}^{\beta} - y_i^{\gamma} \right)^2$$

Здесь требуется подобрать значения для  $w_0, w_1, w_2, \alpha, \beta, \gamma$ . Что из этого будет параметром, а что гиперпараметром? Иными словами, что из этого можно подбирать по обучающей выборке, а что нельзя? Поясните свои ответы.

**Задача 2 (3 балла).** В этой задаче мы будем обсуждать решающие деревья и их композиции.

1. Как известно, решающие деревья обучаются жадным алгоритмом. При построении очередной вершины ключевым шагом является подбор предиката:

$$Q(R_m, j, t) \rightarrow \min_{j, t}$$

Здесь мы выбираем такой предикат  $[x_j > t]$ , при котором, скажем, энтропия в дочерних вершинах будет минимальна. А как именно решается записанная выше задача выбора оптимальных  $j$  и  $t$ ? Например, задача выбора оптимальных весов для линейной регрессии решается градиентным спуском — а как здесь?

2. Говорят, что решающее дерево может идеально подогнаться под любую обучающую выборку (при условии, что там все объекты различны). Почему это так? Поясните на каком-нибудь примере выборки.
3. Ниже записаны формулы для построения  $N$ -й базовой модели  $b_N(x)$  в градиентном бустинге:

$$s_i = - \left. \frac{\partial}{\partial z} L(a_{N-1}(x_i), z) \right|_{a_{N-1}(x_i)}$$

$$\frac{1}{\ell} \sum_{i=1}^{\ell} (b_N(x_i) - y_i)^2 \rightarrow \min_{b_N}$$

Найдите все ошибки. Объясните их. Укажите, как их исправить.

4. Объясните, что из перечисленного ниже является параметрами, а что гиперпараметрами при обучении решающего дерева:
  - Максимальная глубина дерева;
  - Прогнозы в листьях дерева;
  - Размер случайной подвыборки, из которой выбирается оптимальный признак для предиката.
5. Что из перечисленного ниже приведёт к понижению смещения решающего дерева, а что к повышению? Поясните ваши ответы.
  - уменьшение максимально допустимой глубины дерева;
  - обучение дерева на случайном подмножестве признаков (вместо обучения на всех признаках);
  - замена поиска оптимального предиката в каждой вершине на выбор случайного предиката.

**Задача 3 (2 балла).** Ответьте на вопросы по функциям потерь:

1. Ниже записаны некоторые функции потерь для задачи регрессии. В формулах через  $y$  обозначается правильный ответ, через  $z$  — прогноз модели. Объясните, в чём особенности этих функций потерь и где они могут оказаться полезны.

- $\max(1, (y - z)^2)$ ;
- $\min(100, (y - z)^2)$ ;
- $\max(0, y - z)$ .

2. Рассмотрим задачу бинарной классификации. Будем обучать линейный классификатор на следующий функционал:

$$\frac{1}{\ell} \sum_{i=1}^{\ell} (y_i \langle w, x_i \rangle - 1)^2.$$

Почему это будет плохой идеей?

**Задача 4 (2 балла).** Вам выдали классификатор  $b(x)$ , и вам предстоит разобраться, насколько она хороша. Для этого у вас есть тестовая выборка из 8 объектов. Ниже указаны правильные ответы и уверенности модели в положительном классе:

$b(x)$	3	1	7	0	2	9	4	-2
$y$	-1	-1	+1	+1	+1	-1	+1	-1

Выполните следующие шаги:

1. Нарисуйте ROC-кривую и посчитайте AUC-ROC.
2. Посчитайте точность и полноту этой модели при пороге  $t = 5$  (считайте, что мы относим к положительному классу объекты, на которых  $b(x) > t$ ).
3. Можно ли достичь полноты в хотя бы 25% при точности в 100%? Если да, укажите, при каком пороге. Если нет, поясните, почему.
4. Можно ли достичь полноты в 50% при точности в хотя бы 60%? Если да, укажите, при каком пороге. Если нет, поясните, почему.